



Machine Learning y Data Analytics

HW 7 - Grupo 1

Ian Amighini
Julieta Brey
Lorenzo Nasti
Camila Sobrino
Matias Rodriguez Brun

Profesor Titular: Sergio Pernice

Consigna

- 1) A partir del Jupyter notebook "VarCovar", explicar cual es el teorema de la teoría de probabilidades que nos permite estimar valores esperado, varianzas, covarianzas, etc. a partir de datos empíricos.
- 2) Explicar en detalle por que, para calcular valores esperados de las variables, y sus varianzas, es suficiente tener las distribuciones marginales, pero para calcular la covarianza es imprescindible usar la distribución conjunta.
- 3) Generar un Jupyter notebook similar, pero en el que la variable aleatoria X puede tener 3 valores diferentes (x_0, x_1, x_2) e Y cuatro valores diferentes (y_0, y_1, y_2, y_3). Pero antes de eso explicar por qué el número de eventos diferentes es 12, y por lo tanto la distribución de probabilidades conjunta tiene 12 probabilidades diferentes p_{ij} , $i=0,1,2$, $j=0,1,2,3$ (de las cuales 11 son independientes, y la doceava tiene que ser tal que la suma de las 12 de 1 (y todas sean positivas). Notar que la matriz varianza covarianza sigue siendo de 2×2 , porque hay dos variables aleatorias.
- 4) Generar un Jupyter notebook similar, pero con 3 variables aleatorias, X, Y, Z, cada una de las cuales puede tomar dos valores diferentes. Pero antes de eso explicar por qué el número de eventos diferentes es 8 y por lo tanto la distribución de probabilidades conjunta tiene 8 probabilidades diferentes p_{ijk} , $i=0,1$, $j=0,1$, $k=0,1$ (de las cuales 7 son independientes, y la octava tiene que ser tal que la suma de las 8 de 1 (y todas sean positivas). Notar que la matriz varianza covarianza ahora es de 3×3 , porque hay tres variables aleatorias.

Teorema de la Teoría de Probabilidades

En problemas de estadística aplicada, a menudo contamos sólo con datos muestrales de una población desconocida. Para inferir cantidades poblacionales como la esperanza $E[X]$, la varianza $\text{Var}(X)$ o la covarianza $\text{Cov}(X, Y)$, empleamos estimadores basados en promedios y sumas de cuadrados de la muestra. El soporte teórico que valida esta práctica es la **Ley de los Grandes Números (LGN)**, que garantiza la convergencia de estos estimadores hacia los valores verdaderos a medida que n crece.

Ley de los Grandes Números

Sea $\{X_i\}_{i=1}^{\infty}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con $E[X_i] = \mu$ y $\text{Var}(X_i) < \infty$. Entonces, para el promedio muestral

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

se cumple

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{} \mu \quad (\text{convergencia en probabilidad}).$$

Más aún, si $g: \mathbb{R} \rightarrow \mathbb{R}$ verifica $E[|g(X)|] < \infty$, también

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow[n \rightarrow \infty]{} E[g(X)].$$

Estimadores de Momentos

A partir de la LGN se derivan naturalmente los siguientes estimadores:

1. Esperanza

$$\widehat{E[X]} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} E[X].$$

2. Varianza

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \xrightarrow{p} \text{Var}(X).$$

El divisor $n-1$ corrige el sesgo introducido por el uso de \bar{X}_n .

3. Covarianza

$$\widehat{\text{Cov}}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n) (Y_i - \bar{Y}_n) \xrightarrow{p} \text{Cov}(X, Y).$$

Aunque la LGN garantiza la convergencia de los estimadores, el Teorema Central del Límite (TCL) describe la velocidad de esta convergencia y la distribución asintótica de X_n . Bajo condiciones razonables, lo que permite construir intervalos de confianza y realizar contrastes de hipótesis.

Gracias a la Ley de los Grandes Números y su extensión a funciones de la muestra, los estadísticos muestrales X_n , S^2 y $\text{Cov}(X, Y)$ son **consistentes**, es decir, convergen al verdadero valor poblacional.

Distribuciones Marginales y Conjunta en el Cálculo de Momentos

Momentos univariados a partir de la distribución marginal

Sea X una variable aleatoria con función de densidad (o masa) marginal $f_X(x)$.

- **Esperanza:** sólo interviene la marginal, pues promediamos X según su propia distribución.

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

- **Varianza:** nuevamente, basta conocer f_X para medir la dispersión de X .

$$\text{Var}(X) = E[(X - E[X])^2] = \int_{-\infty}^{\infty} (x - E[X])^2 f_X(x) dx.$$

Conclusión:

Para cualquier momento de orden k de X , $E[X^k] = \int x^k f_X(x) dx$, es suficiente disponer de la función marginal f_X .

Covarianza y la necesidad de la distribución conjunta

Para dos variables X y Y, la covarianza se define como

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

- Los términos $E[X]$ y $E[Y]$ se obtienen de las marginales f_X y f_Y , respectivamente.

- El núcleo del cálculo es $\rightarrow E[XY] = \iint xy f_{X,Y}(x, y) dx dy$, donde $f_{X,Y}(x,y)$ es la **densidad conjunta** de (X,Y).

Razón fundamental:

El valor medio de XY pondera la probabilidad de que simultáneamente $X \approx x$ y $Y \approx y$. Esa probabilidad –es decir, la dependencia entre X y Y– **no** puede inferirse a partir de f_X y f_Y por separado, excepto en el caso especial en que X e Y sean independientes (donde $f_{X,Y} = f_X f_Y$).

Implicaciones prácticas para el notebook “VarCovar”

Momentos univariados

- Se calculan con muestras de una sola variable: $\bar{X}_n \rightarrow E[X]$ y $S^2 \rightarrow \text{Var}(X)$.
- Sólo requieren la distribución marginal empírica de X

Covarianza

El estimador
$$\widehat{\text{Cov}}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)$$
 explota la frecuencia empírica de los pares (X_i, Y_i) .

Es imprescindible emplear la **distribución conjunta** (o datos emparejados) para capturar la relación lineal entre ambas variables.

Resumen:

- **Distribución marginal** \rightarrow basta para esperanzas y varianzas univariadas.
- **Distribución conjunta** \rightarrow necesaria para covarianzas y demás momentos multivariados.

Jupyter Notebook 1

Explicación de los 12 eventos

Cuando consideramos dos variables discretas, X con tres posibles valores (0, 1 y 2) e Y con cuatro (0, 1, 2 y 3), cada combinación de un valor de X con uno de Y constituye un suceso único y mutuamente excluyente: por ejemplo, “X=0 y Y=0”, “X=0 y Y=1”, ..., hasta “X=2 y Y=3”. En total hay $3 \times 4 = 12$ de estos sucesos elementales, de modo que la distribución conjunta debe asignarles una probabilidad p_{ij} distinta para cada par (i,j). Es decir, disponemos de doce probabilidades $p_{00}, p_{01}, \dots, p_{23}$. Sin embargo, para que esto sea una distribución válida, esas doce magnitudes deben sumar exactamente 1 (y ser no negativas), lo que impone una sola ecuación de normalización:

$$\sum_{i=0}^2 \sum_{j=0}^3 p_{ij} = 1.$$

Debido a esta restricción global, bastan once parámetros libres: uno puede elegir arbitrariamente once de los p_{ij} (siempre comprobando que queden positivos), y la duodécima probabilidad queda obligatoriamente determinada para que la suma total sea uno. Así, la tabla de probabilidades conjunta es de dimensión $3 \times 4 = 12$, pero sólo once de sus entradas son independientes; la última se calcula como

$$p_{2,3} = 1 - \sum_{\substack{0 \leq i \leq 2, 0 \leq j \leq 3 \\ (i,j) \neq (2,3)}} p_{ij}.$$

NoteBook

```
✓ [1] import numpy as np
0 s

# Definir los valores posibles
x_vals = np.array([0, 1, 2]) # x0, x1, x2
y_vals = np.array([0, 1, 2, 3]) # y0, y1, y2, y3
```

```
# 3. Distribución conjunta de ejemplo - Generamos una matriz 3x4 de valores aleatorios y la normalizamos.
```

```
P = np.random.rand(len(x_vals), len(y_vals))
P = P / P.sum() # Normalizar a suma 1
print("Distribución conjunta P:")
print(P)
```

```
· Distribución conjunta P:
```

```
[[0.02956629 0.13923808 0.0564028  0.05831484]
 [0.05747919 0.15613068 0.14529197 0.11599674]
 [0.05612531 0.02214805 0.1209679  0.04233816]]
```

```
# 4. Distribuciones marginales
```

```
# -  $p_X(i) = \sum_j P[i,j]$ 
```

```
# -  $p_Y(j) = \sum_i P[i,j]$ 
```

```
# Marginal de X (suma por filas)
```

```
p_x = P.sum(axis=1)
```

```
# Marginal de Y (suma por columnas)
```

```
p_y = P.sum(axis=0)
```

```
print("\nMarginal de X:", p_x)
```

```
print("Marginal de Y:", p_y)
```

```
Marginal de X: [0.283522  0.47489859 0.24157942]
```

```
Marginal de Y: [0.14317079 0.31751681 0.32266267 0.21664973]
```

```
#5. Cálculo de esperanzas
```

```
#  $E[X] = \sum_i x_i p_X(i)$ 
```

```
#  $E[Y] = \sum_j y_j p_Y(j)$ 
```

```
E_X = np.dot(x_vals, p_x)
```

```
E_Y = np.dot(y_vals, p_y)
```

```
print(f"E[X] = {E_X:.4f}")
```

```
print(f"E[Y] = {E_Y:.4f}")
```

```
E[X] = 0.9581
```

```
E[Y] = 1.6128
```

```
#6. Cálculo de varianzas
```

```
#  $Var(X) = \sum_i (x_i - E[X])^2 p_X(i)$ 
```

```
#  $Var(Y) = \sum_j (y_j - E[Y])^2 p_Y(j)$ 
```

```
Var_X = np.dot((x_vals - E_X)**2, p_x)
```

```
Var_Y = np.dot((y_vals - E_Y)**2, p_y)
```

```
print(f"Var(X) = {Var_X:.4f}")
```

```
print(f"Var(Y) = {Var_Y:.4f}")
```

```
· Var(X) = 0.5233
```

```
Var(Y) = 0.9569
```

#7. Cálculo de la covarianza

$\text{Cov}(X,Y) = E[XY] - E[X]E[Y]$, donde
$E[XY] = \sum_i \sum_j x_i y_j P[i,j]$

$E[XY]$

```
E_XY = sum(x * y * P[i, j] for i, x in enumerate(x_vals) for j, y in enumerate(y_vals))  
Cov_XY = E_XY - E_X * E_Y  
print(f"Cov(X,Y) = {Cov_XY:.4f}")
```

$\text{Cov}(X,Y) = 0.0318$

8. Matriz varianza-covarianza

Construimos la matriz 2x2 - Notar que la matriz varianza covarianza sigue siendo de 2x2, porque hay dos variables aleatorias.

```
Sigma = np.array([[Var_X, Cov_XY], [Cov_XY, Var_Y]])  
print("\nMatriz Var-Cov:")  
print(Sigma)
```

Matriz Var-Cov:
[[0.52334223 0.03175477]
 [0.03175477 0.95691915]]

Jupyter Notebook 2

En el caso de tres variables aleatorias discretas X,Y,Z , cada una con **dos posibles valores** (por ejemplo 0 y 1), el **espacio muestral conjunto** está formado por todos los tripletes (x_i, y_j, z_k)

con $i \in \{0, 1\}, j \in \{0, 1\}, k \in \{0, 1\}$.

El número total de combinaciones es el producto del número de valores de cada variable:

$$\underbrace{2}_{\#X} \times \underbrace{2}_{\#Y} \times \underbrace{2}_{\#Z} = 8.$$

Ocho probabilidades conjuntas p_{ijk}

A cada uno de esos 8 eventos ($X=i, Y=j, Z=k$) le asignamos una probabilidad

$p_{ijk} = P(X=i, Y=j, Z=k)$ con índices $i, j, k \in \{0, 1\}$. En total hay **8** de ellas:

$$\{p_{000}, p_{001}, p_{010}, p_{011}, p_{100}, p_{101}, p_{110}, p_{111}\}.$$

Para que $\{p_{ijk}\}$ formen una **distribución de probabilidad** válida, deben cumplirse dos axiomas:

1. **No negatividad** $p_{ijk} \geq 0 \quad \forall i, j, k.$

$$\sum_{i=0}^1 \sum_{j=0}^1 \sum_{k=0}^1 p_{ijk} = 1.$$

2. Normalización

Grados de libertad

- Partimos de 8 variables p_{ijk}
- La **condición de suma uno** es una ecuación lineal que las une.
- Por tanto, hay **$8 - 1 = 7$ grados de libertad**: podemos elegir libremente 7 de las probabilidades, y la octava **queda determinada** automáticamente para que la suma sea 1.

¿Por qué importa?

- Cada p_{ijk} cuantifica la probabilidad de un evento conjunto (X, Y, Z).
- Conocer las 7 primeras y aplicar la normalización **asegura que la distribución completa sea coherente**.
- Este esquema es la base para definir la **distribución conjunta** y, a partir de ella, derivar marginales, esperanzas, varianzas, covarianzas y la matriz var-cov 3×3 .

```
[8] import numpy as np

# 1. Definir los valores posibles para cada variable
x_vals = np.array([0, 1])
y_vals = np.array([0, 1])
z_vals = np.array([0, 1])
```

```
# 2. Generar distribución conjunta aleatoria y normalizar
P = np.random.rand(2, 2, 2)
P /= P.sum()
print("Distribución conjunta P:", P)
```

```
Distribución conjunta P: [[[0.17524946 0.15783242]
 [0.16183824 0.11335305]]
 [[0.15583243 0.07961889]
 [0.02664769 0.12962782]]]
```

```
# 3. Calcular distribuciones marginales
p_x = P.sum(axis=(1, 2)) # marginal de X
p_y = P.sum(axis=(0, 2)) # marginal de Y
p_z = P.sum(axis=(0, 1)) # marginal de Z
print("Marginal X:", p_x)
print("Marginal Y:", p_y)
print("Marginal Z:", p_z)
```

```
Marginal X: [0.60827316 0.39172684]
Marginal Y: [0.56853321 0.43146679]
Marginal Z: [0.51956782 0.48043218]
```

```
# 4. Calcular esperanzas
E_X = np.dot(x_vals, p_x)
E_Y = np.dot(y_vals, p_y)
E_Z = np.dot(z_vals, p_z)
print(f"E[X] = {E_X:.4f}")
print(f"E[Y] = {E_Y:.4f}")
print(f"E[Z] = {E_Z:.4f}")
```

```
E[X] = 0.3917
E[Y] = 0.4315
E[Z] = 0.4804
```

```
# 5. Calcular varianzas
Var_X = np.dot((x_vals - E_X)**2, p_x)
Var_Y = np.dot((y_vals - E_Y)**2, p_y)
Var_Z = np.dot((z_vals - E_Z)**2, p_z)
print(f"Var(X) = {Var_X:.4f}")
print(f"Var(Y) = {Var_Y:.4f}")
print(f"Var(Z) = {Var_Z:.4f}")
```

```
Var(X) = 0.2383
Var(Y) = 0.2453
Var(Z) = 0.2496
```

```
# 5. Calcular varianzas
Var_X = np.dot((x_vals - E_X)**2, p_x)
Var_Y = np.dot((y_vals - E_Y)**2, p_y)
Var_Z = np.dot((z_vals - E_Z)**2, p_z)
print(f"Var(X) = {Var_X:.4f}")
print(f"Var(Y) = {Var_Y:.4f}")
print(f"Var(Z) = {Var_Z:.4f}")
```

```
Var(X) = 0.2383
Var(Y) = 0.2453
Var(Z) = 0.2496
```

Código

1_HW7_VarCovar.ipynb